PROJET M2 · DATA ENGINEERING & DATA ANALYSE

# Boréal Assurances

Construire la chaîne de données et analyser le portefeuille d'un assureur IARD

Nom

**Andrea KOFFI**

Rendu le

**23 octobre 2026**

## Table des matières


Introduction ..... 3
Contexte ..... 3
Pipeline construit : ..... 3
Livrable 1 · Architecture et ingestion ..... 3
1.1 Architecture cible ..... 3
1.2 Ingestion des sources ..... 5
1.3 Chargement incrémental ..... 6
Livrable 2 · Qualité des données et modélisation ..... 7
2.1 Contrôles et quarantaine ..... 7
2.2 Déduplication des clients ..... 8
2.3 Modèle dimensionnel (core) ..... 9
2.4 Tests automatisés ..... 10
Livrable 3 · Analyse technique du portefeuille ..... 11
3.1 Indicateurs techniques par axe ..... 11
3.2 Évolution annuelle et décomposition de la variation du ratio ..... 13
3.3 Rigueur statistique descriptive ..... 15
Livrable 4 · Analyse clients et gestion des sinistres ..... 16
4.1 Cohortes par produit et multi-détention ..... 16
4.2 Valeur observée des clients ..... 18
4.3 Délais, audits et fraude ..... 20
Livrable 5 · Dashboard, exploitation et documentation ..... 22
5.1 Dashboard interactif ..... 22
5.2 Orchestration, alertes et documentation ..... 23
5.3 Gouvernance et analyse RGPD ..... 25
Conclusion ..... 26
Annexes ..... 26


Lien depot GITHUB: **https://github.com/andreawendys/boreal-AndreaKoffi**

# Introduction

### Contexte

Boréal Assurances est un assureur de dommages (auto et habitation) qui gère 20 264 contrats et 2 805 sinistres déclarés entre janvier 2020 et juin 2025. La dispersion des données rend les analyses difficiles et les indicateurs peu fiables. La mission est donc de créer une source unique de vérité, mise à jour sans intervention manuelle, et un tableau de bord de suivi.

### Pipeline construit :

Nous avons bâti une chaîne de données complète, de l'archive de fichiers jusqu'au graphique. Elle se lance avec une seule commande et se déroule en sept étapes :

1. **Chargement dans le brut (raw).** Nous copions les 68 fichiers tels quels, avec le fichier d'origine et la date de chargement de chaque ligne. Un journal note chaque fichier chargé.
2. **Tests du brut.** Six tests vérifient que rien n'a été perdu ni modifié, et qu'un mois rechargé ne crée aucun doublon.
3. **Préparation (prep).** Nous donnons leur type aux colonnes (dates, nombres) et unifions les montants.
4. **Contrôles de qualité.** 23 règles détectent les anomalies. Les lignes écartées vont en quarantaine avec leur motif, aucune n'est supprimée.
5. **Cœur (core).** Nous dédoublonnons les clients et construisons le schéma en étoile : 5 dimensions et 3 tables de faits.
6. **Tests du cœur.** Treize tests vérifient les clés, les liens entre tables et la réconciliation des règlements. Un seul échec arrête toute la chaîne et déclenche une alerte.
7. **Marts.** Nous calculons une seule fois les indicateurs, que le dashboard Streamlit lit ensuite sans rien recalculer.

Un déclencheur planifié vérifie chaque jour si un nouveau fichier mensuel de règlements est arrivé, et ne relance la chaîne que dans ce cas. Les alertes d'échec sont écrites dans un fichier dédié.

# Livrable 1 · Architecture et ingestion

Ce premier livrable répond à trois questions : comment est organisée la chaîne de données, comment les cinq sources y entrent, et comment nous sommes sûrs qu'un mois chargé deux fois ne compte pas deux fois.

### 1.1 Architecture cible

Nous avons défini la chaîne de bout en bout avant d'écrire du code. Les données traversent cinq couches : les sources, le brut, la préparation, le cœur et les marts, qui alimentent le dashboard. Chaque couche lit uniquement la précédente et écrit uniquement dans la sienne. Si un chiffre est contesté, on remonte ainsi couche par couche jusqu'à la ligne du fichier d'origine.

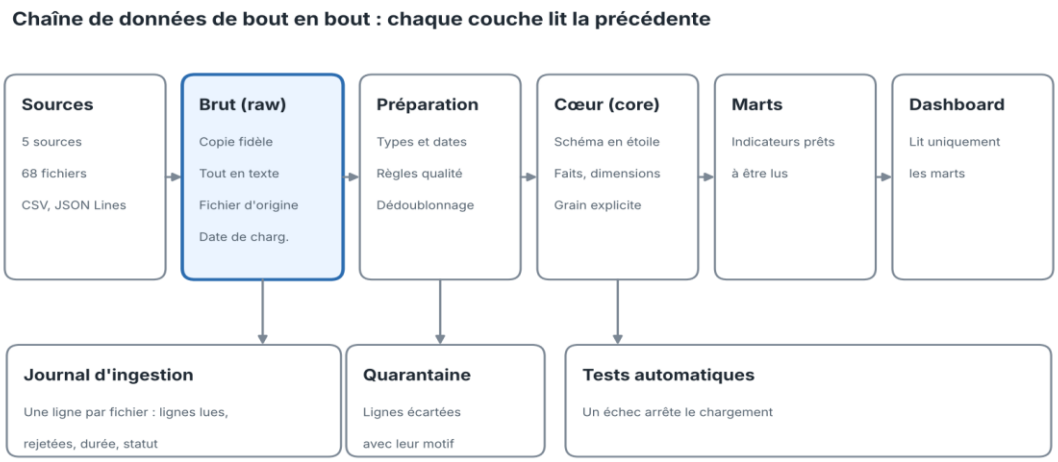



*Figure 1 : chaîne de données de bout en bout (les noms des schémas sont en anglais : raw = brut, prep = préparation, core = cœur)*

Le brut est une copie fidèle des sources, sans aucune correction. La préparation donne leur type aux colonnes et met les lignes douteuses en quarantaine avec leur motif. Le cœur organise les données en schéma en étoile. Les marts contiennent les indicateurs que le dashboard affiche, et lui seul les lit. Le journal d'ingestion, la quarantaine et les tests accompagnent la chaîne.

### Choix des outils et justification

Le volume à traiter est modeste : 41 848 lignes réparties dans 68 fichiers, soit environ 2,5 Mo. Nous avons donc cherché des outils simples, sans serveur à administrer. Chaque outil est justifié par un critère que l'on peut mesurer.

| Outil | Rôle | Critère mesurable |
|---|---|---|
| DuckDB | Entrepôt et moteur SQL | Volumétrie : 41 848 lignes chargées en environ 4 secondes, base d'environ 5 Mo. Coût : 0 €. Maintenance : un seul fichier, aucun serveur. Il lit directement les CSV et le JSON Lines. |
| Python 3.10+ | Ingestion, tests, orchestration | Bibliothèques listées dans requirements.txt, installées en une commande. |
| SQL | Transformations des couches | SQL standard, portable vers PostgreSQL. Une couche correspond à un dossier de fichiers .sql. |
| Git et GitHub | Versionnement | Maintenance : historique des modifications, dépôt reproductible par une autre personne. |
| Orchestrateur Python (run_all.py) et planificateur Windows | Enchaînement des étapes, déclenchement à l'arrivée d'un fichier | Maintenance : aucun service à héberger. La chaîne de 7 étapes s'exécute en 11 à 14 secondes. Compatible Windows |
| Streamlit et Plotly | Dashboard | Compétences : Python. Lit les marts en lecture seule, une page correspond à une partie du fichier app.py. |
| pandas et scipy | Analyses statistiques | Intervalles de confiance et tests statistiques disponibles sans développement. |

**Pourquoi un orchestrateur en Python plutôt que Makefile, Prefect, Airflow ou Dagster ?** Le sujet laisse le choix. Nous avons écarté Makefile parce qu'il n'est pas natif sous Windows. Prefect, Airflow et Dagster sont faits pour des dizaines de tâches qui dépendent les unes des autres ; notre

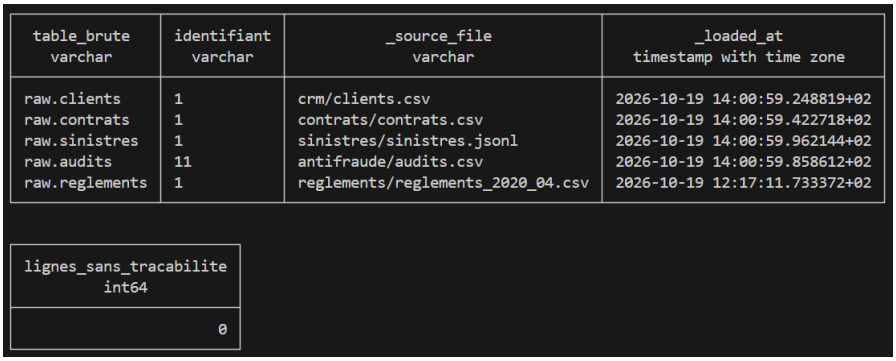
chaîne est une suite linéaire de sept étapes, avec environ cinq fichiers par mois. Un script Python d'une centaine de lignes (pipeline/run_all.py) est reproductible, s'arrête au premier test en échec et prévient en cas de problème. Un orchestrateur complet ajouterait un serveur à maintenir pour un bénéfice nul à cette échelle.

### Avec 100 fois plus de données

Cela représenterait environ 4,2 millions de lignes et 250 Mo. DuckDB resterait utilisable, car son stockage en colonnes supporte ces volumes sur un poste. Ce qui changerait, c'est l'exploitation. Un seul processus peut écrire à la fois dans le fichier de la base, ce qui ne convient plus à plusieurs utilisateurs : nous passerions à PostgreSQL ou à un entrepôt cloud. Le chargement se ferait par partitions mensuelles, sans rechargement complet. L'orchestrateur Python laisserait la place à Airflow ou Dagster, pour gérer les reprises, les dépendances multiples et les alertes.

## 1.2 Ingestion des sources

Nous avons chargé les cinq sources dans la couche brute avec un script Python, pipeline/ingest.py. Toutes les valeurs sont lues en texte et aucune n'est corrigée à cette étape. Chaque ligne conserve deux colonnes de traçabilité : _source_file (le fichier d'origine) et _loaded_at (la date de chargement).



| table_brute<br>varchar | identifiant<br>varchar | _source_file<br>varchar | _loaded_at<br>timestamp with time zone |
|---|---|---|---|
| raw.clients | 1 | crm/clients.csv | 2026-10-19 14:00:59.248819+02 |
| raw.contrats | 1 | contrats/contrats.csv | 2026-10-19 14:00:59.422718+02 |
| raw.sinistres | 1 | sinistres/sinistres.jsonl | 2026-10-19 14:00:59.962144+02 |
| raw.audits | 11 | antifraude/audits.csv | 2026-10-19 14:00:59.858612+02 |
| raw.reglements | 1 | reglements/reglements_2020_04.csv | 2026-10-19 12:17:11.733372+02 |

| lignes_sans_tracabilite<br>int64 |
|---|
| 0 |

*Figure 2 : récapitulatif du chargement des cinq sources dans la couche brute*

Les différences de format, d'encodage et de structure sont gérées sans intervention manuelle. Le séparateur et l'encodage sont fixés à la lecture de chaque source dans SQL/02 prep :

| Source | Format | Particularité | Lignes | Table brute |
|---|---|---|---|---|
| CRM | CSV, séparateur ; | Encodage latin-1, dates jj/mm/aaaa | 15 200 | raw.clients |
| Contrats | CSV, séparateur , | UTF-8, dates ISO | 20 264 | raw.contrats |
| Sinistres | JSON Lines | Un objet par ligne | 2 805 | raw.sinistres |
| Règlements | 64 CSV mensuels | Colonnes différentes en mars 2024 | 3 207 | raw.reglements |
| Audits | CSV, séparateur , | Dossiers contrôlés uniquement | 372 | raw.audits |

- **Structure entre fichiers d'une même source :** le fichier de mars 2024 nomme sa colonne des valeurs montant_eur au lieu de montant, et la place en première position. Nous insérons donc les règlements par nom de colonne et non par position, sinon des identifiants et des montants se seraient mélangés sans aucune erreur visible. La table brute contient les deux colonnes : montant

pour les 63 autres mois et montant_eur pour mars 2024. Un test vérifie que chaque règlement a exactement un montant. La fusion en une seule colonne est faite en phase de préparation.

| paiement_id varchar | montant varchar | montant_eur varchar | _source_file varchar |
|---|---|---|---|
| 1109 | NULL | 1288.22 | reglements/reglements_2024_03.csv |
| 1336 | NULL | 141.51 | reglements/reglements_2024_03.csv |
| 1543 | NULL | 192.05 | reglements/reglements_2024_03.csv |

*Figure 3 : règlements de mars 2024 : montant vide, montant_eur rempli, _source_file visible*

## 1.3 Chargement incrémental

### Journal d'ingestion

Nous avons créé la table meta.ingestion_log, qui reçoit une ligne par fichier chargé : nom du fichier, source, empreinte du contenu (SHA-256), lignes lues, lignes rejetées, durée, statut et date. En couche brute, aucune ligne n'est rejetée volontairement : la colonne des lignes rejetées vaut 0, et un fichier illisible serait enregistré avec le statut ECHEC. Les rejets liés aux règles métier sont traités par la quarantaine, à partir de la préparation. L'empreinte permet de savoir si un fichier a changé même s'il porte le même nom.

| fichier varchar | lignes_lues int64 | lignes_rejetees int64 | duree_s double | statut varchar |
|---|---|---|---|---|
| reglements/reglements_2024_03.csv | 86 | 0 | 0.026 | OK |
| reglements/reglements_2024_03.csv | 86 | 0 | 0.053 | OK |
| sinistres/sinistres.jsonl | 2805 | 0 | 0.021 | OK |
| antifraude/audits.csv | 372 | 0 | 0.097 | OK |
| contrats/contrats.csv | 20264 | 0 | 0.44 | OK |

*Figure 4 : synthèse du journal d'ingestion par source (fichiers chargés, lignes lues, statut)*

### Procédure de rechargement d'un mois

Le rechargement d'un mois de règlements se lance avec une seule commande :

```
python pipeline/ingest.py --mois 2024_03
```

Un fichier déjà chargé avec la même empreinte est ignoré lors d'un chargement normal. Lors d'un rechargement, le script supprime uniquement les lignes de ce fichier puis les réinsère, dans une transaction. En cas d'erreur, la transaction est annulée, aucun mois n'est perdu et l'échec est inscrit au journal. Un mois qui n'existe pas (par exemple --mois 1999_01) est refusé avant toute modification, avec un message clair.

```
reglements_2024_03.csv rechargé (OK) : 3207 -> 3207 lignes au total
```

*Figure 5 : rechargement de mars 2024 : le total reste à 3 207 lignes*

### Preuve par un test : aucun doublon au rejeu

Le test test_rejeu_sans_doublon fait partie des six tests de la couche brute, regroupés dans le fichier tests/test_brut.py et lancés par la commande python tests/test_brut.py. Il travaille sur une copie de l'entrepôt, pour ne pas toucher aux vraies données. Il recharge deux fois de suite les règlements de mars 2024 par exemple, puis vérifie que le total des règlements (3 207) et le nombre de lignes du mois (86) n'ont pas changé. Les cinq autres tests vérifient la réconciliation avec les fichiers sources, la traçabilité de chaque ligne, le journal d'ingestion, l'unicité du jeu de lignes par fichier de règlements et la gestion des montants de mars 2024. Dans notre cas, les six réussissent.

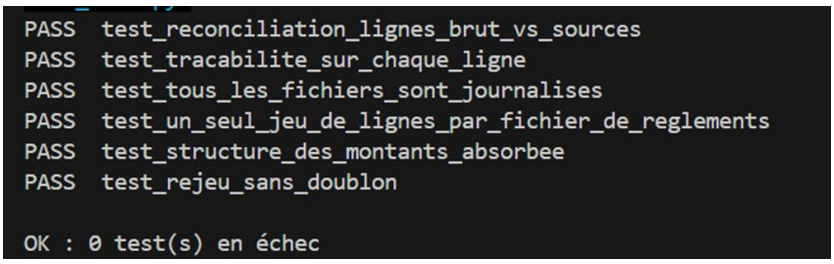



*Figure 6 : exécution des six tests de la couche brute*

**Interprétation de l'exemple du sujet**

L'exemple insère les règlements de la préparation vers le cœur seulement si leur paiement_id n'existe pas déjà (NOT EXISTS). Au second passage, la sélection renvoie les mêmes lignes qu'au premier, mais chaque paiement_id est désormais dans la table cible : la condition est fausse pour toutes, donc aucune ligne n'est insérée et la table reste identique. Nous le prouvons par un comptage avant et après le rejeu (3 207 lignes avant, 3 207 après), confirmé par le test test_rejeu_sans_doublon. En brut, la protection repose sur le remplacement des lignes par fichier et sur l'empreinte du contenu ; en cœur, le NOT EXISTS écarte aussi les 32 paiements livrés en double dans des fichiers de mois différents.

## Livrable 2 · Qualité des données et modélisation

Les sources de Boréal sont réalistes, donc imparfaites. Ce livrable explique comment nous avons détecté, chiffré et traité les défauts, puis comment nous avons organisé les données propres en schéma en étoile.

### 2.1 Contrôles et quarantaine

Nous avons défini 23 règles de qualité. Chaque règle est une requête SQL qui renvoie les lignes en anomalie, avec leur clé et la valeur en cause. Un script Python, pipeline/qualite.py, les exécute toutes sur la couche de préparation et range le résultat dans trois tables du schéma qualite :

- **qualite.anomalies :** toutes les lignes détectées, avec la règle, le motif et le traitement.
- **qualite.quarantaine :** les lignes écartées du cœur (traitements « exclure » et « corriger »), avec leur motif.
- **qualite.registre :** la définition de chaque règle (famille, gravité, traitement, requête) et le volume constaté.

Aucune ligne n'est supprimée des tables de préparation. Une ligne écartée reste retrouvable par sa clé et son motif, ce qui permet de réconcilier avec la source et d'expliquer tout écart de total.

**Les règles, leur gravité et leur traitement**

Les règles couvrent les cinq familles demandées : complétude, unicité, validité, cohérence entre tables et cohérence temporelle et sont exécutées par le pipeline/qualite.py à chaque lancement.

| id<br>varchar | categorie<br>varchar | gravite<br>varchar | traitement<br>varchar | volume<br>int64 |
|---|---|---|---|---|
| Q01 | Complétude | Mineure | Signaler | 226 |
| Q02 | Complétude | Bloquante | Exclure | 0 |
| Q03 | Complétude | Bloquante | Exclure | 0 |
| Q04 | Unicité | Majeure | Corriger | 200 |
| Q05 | Unicité | Bloquante | Exclure | 0 |
| Q06 | Unicité | Bloquante | Exclure | 0 |
| Q07 | Unicité | Majeure | Exclure | 32 |
| Q08 | Validité | Majeure | Exclure | 25 |
| Q09 | Validité | Mineure | Signaler | 18 |
| Q10 | Validité | Majeure | Signaler | 22 |
| Q11 | Validité | Bloquante | Exclure | 0 |
| Q12 | Validité | Majeure | Signaler | 0 |
| Q13 | Validité | Majeure | Signaler | 1 |
| Q14 | Cohérence entre tables | Bloquante | Exclure | 0 |
| Q15 | Cohérence entre tables | Bloquante | Exclure | 0 |
| Q16 | Cohérence entre tables | Bloquante | Exclure | 0 |
| Q17 | Cohérence entre tables | Majeure | Signaler | 0 |
| Q18 | Cohérence entre tables | Majeure | Signaler | 0 |
| Q19 | Cohérence temporelle | Bloquante | Exclure | 26 |
| Q20 | Cohérence temporelle | Majeure | Signaler | 15 |
| Q21 | Cohérence temporelle | Majeure | Signaler | 18 |
| Q22 | Cohérence temporelle | Majeure | Signaler | 0 |
| Q23 | Cohérence temporelle | Majeure | Signaler | 0 |

23 rows 5 columns

*Figure 7 : registre des règles de qualité (qualite.registre), volume constaté pour chaque règle*

### Choix des traitements

Nous avons appliqué trois traitements, selon ce que l'anomalie change pour les calculs :

- **Exclure (83 lignes) :** la ligne fausserait un indicateur si elle restait. Il s'agit de 32 copies de paiements rejouées dans un mois qui n'est pas le leur, de 25 contrats à prime nulle ou négative et de 26 contrats résiliés avant ou le jour de leur effet, dont l'exposition serait nulle ou négative.
- **Corriger (200 lignes) :** les 200 clients en double sont rattachés au client conservé, comme décrit en 2.2.
- **Signaler (300 lignes) :** la ligne reste utilisable, mais elle est tracée. C'est le cas de 226 dates de naissance absentes, 18 naissances avant 1920, 22 titulaires mineurs, une réserve supérieure à un million d'euros, 15 déclarations antérieures à la survenance et 18 sinistres survenus hors de la période de couverture du contrat.

Au total, 283 lignes sont placées en quarantaine. Treize règles ne trouvent aucune anomalie. Nous les gardons : elles prouvent que le contrôle a été fait, et elles s'exécuteront à chaque chargement.

### Points d'attention relevés

- Les 32 paiements rejoués existent chacun en deux copies, dont une est dans le fichier du bon mois. Nous gardons celle-là et écartons l'autre. Il reste 3 175 paiements, tous distincts.
- Les 51 contrats écartés (25 + 26, sans recoupement) ont 5 sinistres. Nous les retirons du calcul de l'exposition, mais nous gardons ces sinistres, marqués dans le cœur, pour ne rien perdre.
- Sur les 18 sinistres hors couverture, 12 ont des règlements. Ils sont signalés et non exclus, pour la raison donnée plus haut.
- Le sinistre 1129 (réserve de 1 252 690 € et paiements jusqu'à 2 475 975 €) est conservé et signalé : valeur extrême probable, mais pas erreur prouvée. Nous mesurons son poids dans toutes les analyses (Livrable 3).

## 2.2 Déduplication des clients

### Clé de rapprochement

Nous avons choisi email_hash, l'empreinte de l'adresse e-mail. C'est le seul identifiant d'une personne qui soit à la fois stable et renseigné sur toutes les lignes. Les autres colonnes ne conviennent pas.

### Taux de doublons

Le CRM contient 15 200 lignes pour 15 000 personnes distinctes. Il y a donc 200 doublons, soit un taux de 1,32 % (200 sur 15 200).

| clients<br>int64 | personnes<br>int64 | doublons<br>int64 | taux_pct<br>double | contrats_sur_doublons<br>int64 |
|---|---|---|---|---|
| 15200 | 15000 | 200 | 1.32 | 0 |

*Figure 8 : taux de doublons et contrats rattachés à un doublon*

### Règle de survie

Pour chaque groupe, nous conservons le plus petit client_id. La règle est simple et donne toujours le même résultat quel que soit l'ordre de chargement. Les 200 personnes dupliquées ont 275 contrats, et tous sont rattachés au client conservé : aucun contrat n'est attaché à un client écarté, donc il n'y a rien à réaffecter .

Si le cas se présentait, la table core.pont_client_survivant donne pour chaque client l'identifiant à conserver. La dimension contrat reprend cet identifiant : les contrats seraient rattachés au client conservé, sans modifier la source. Les 200 clients écartés sont placés en quarantaine (règle Q04), avec l'identifiant du client conservé indiqué dans le détail.

## 2.3 Modèle dimensionnel (core)

Le cœur est un schéma en étoile : trois tables de faits, qui contiennent les mesures, reliées à cinq dimensions, qui décrivent le contexte. Chaque table de faits a un grain explicite, c'est-à-dire que nous savons ce que représente exactement une ligne.

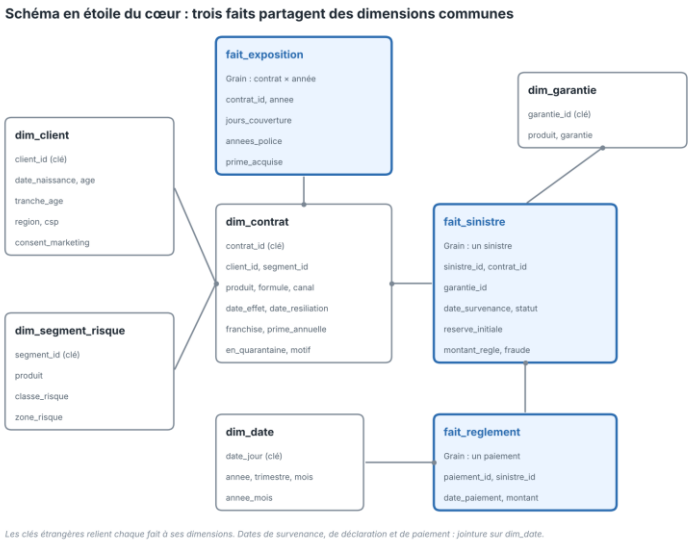



*Figure 9 : schéma en étoile du cœur (core)*

### Tables de faits et grain

| Table | Grain (une ligne =) | Mesures | Lignes |
|---|---|---|---|
| fait_exposition | Un contrat pour une année civile | jours_couverture, annees_police, prime_acquise | 65 103 |
| fait_sinistre | Un sinistre | reserve_initiale, montant_regle, nb_reglements, fraude_confirmee | 2 805 |
| fait_reglement | Un paiement | montant | 3 175 |

L'exposition est la durée de couverture en années-police : le nombre de jours couverts divisé par le nombre de jours de l'année civile (365 ou 366), borné à la date d'extraction du 30 juin 2025. Une année entière de couverture vaut donc exactement 1, et 2025 est comptée pour six mois seulement. Nous avons choisi le grain contrat par année parce que la fréquence des sinistres se calcule par année-police : une ligne par année permet de comparer les années et de découper l'exposition par segment sans double comptage. Le grain du règlement est le paiement, ce qui évite de perdre le détail des acomptes.

**Dimensions**

| Dimension | Contenu | Choix de conception | Lignes |
|---|---|---|---|
| dim_client | Âge, tranche d'âge, région, CSP, consentement marketing | Clients conservés uniquement, après déduplication | 15 000 |
| dim_contrat | Produit, formule, canal, dates, franchise, prime, segment | Tous les contrats conservés, avec un indicateur de quarantaine | 20 264 |
| dim_garantie | Produit et garantie | Clé sur le couple (produit, garantie), car le vol existe en auto et en habitation | 8 |
| dim_segment_risque | Produit, classe de risque, zone de risque | Auto : classe selon le bonus-malus. Habitation : classe selon la surface | 30 |
| dim_date | Jour, année, trimestre, mois | Un jour par ligne, du 1er janvier 2020 au 30 juin 2025 | 2 008 |

Nous avons gardé les 51 contrats en quarantaine dans la dimension contrat, avec un indicateur et leur motif, pour que les cinq sinistres rattachés conservent un contrat existant. Seule l'exposition les exclut, puisque c'est elle qui serait faussée.

**Gestion de l'historique d'une dimension**

Pour les dimensions client et contrat, nous avons retenu le type 1 : une valeur modifiée remplace l'ancienne, sans conserver de version. Les sources fournissent un seul état à la date d'extraction, sans date de changement. Un type 2, qui crée une ligne par version avec des dates de début et de fin, obligerait à inventer ces dates et donnerait une apparence d'historique sans information réelle derrière.

La limite est assumée : si un client change de région, nous ne gardons pas l'ancienne valeur. Le grain contrat par année prépare le passage au type 2 : si la source indiquait un jour les changements de segment de risque, il suffirait de versionner cette dimension, et le fait d'exposition choisirait pour chaque année la version en vigueur.

### 2.4 Tests automatisés

Nous avons écrit 13 tests pour le cœur, dans tests/test_coeur.py. Chaque test compte les anomalies qu'il trouve : zéro signifie qu'il est réussi. Si un seul échoue, le script s'arrête avec un code d'erreur, ce qui interrompt le chargement. Ils s'ajoutent aux 6 tests du brut du Livrable 1, soit 19 tests au total.

| Famille | Test | Ce qu'il vérifie |
|---|---|---|
| Unicité | cles_dimensions_uniques, cles_faits_uniques | Aucune clé en double dans les cinq dimensions ni dans les trois faits (contrat et année pour l'exposition) |
| Unicité | aucun_client_en_double | Deux clients du cœur ne partagent jamais le même email_hash |

| Famille | Test | Ce qu'il vérifie |
|---|---|---|
| Intégrité | integrite_contrat_vers_client, integrite_sinistre_vers_contrat_et_garantie, integrite_reglement_vers_sinistre, integrite_exposition_vers_contrat | Chaque clé étrangère trouve sa ligne dans la table référencée |
| Réconciliation | reconciliation_reglements_brut_vers_coeur | Préparation = cœur + quarantaine, en nombre de lignes (3 207 = 3 175 + 32) et en montant |
| Réconciliation | reconciliation_clients_et_contrats | Aucun client ni contrat perdu entre la préparation et le cœur |
| Réconciliation | montants_sinistres_egaux_aux_reglements | Le total réglé par sinistre égale le total des paiements du cœur |
| Exposition | exposition_toujours_positive | Aucune ligne avec une durée ou une exposition nulle ou négative |
| Exposition | exposition_au_plus_une_annee_et_avant_extraction | Aucune exposition annuelle supérieure à 1 ni aucune date après le 30/06/2025 |
| Exposition | contrats_actifs_tous_exposes | Tout contrat non écarté a au moins une ligne d'exposition |




*Figure 10 : exécution des 13 tests de la couche cœur*

Ces tests ne sont pas lancés à la main. La commande python pipeline/run_all.py enchaîne le chargement, les tests du brut, la préparation, les contrôles de qualité, le cœur, les tests du cœur et les marts. Si un test échoue, la chaîne s'arrête avant de construire les marts : le dashboard continue d'afficher les derniers chiffres validés, jamais des chiffres douteux. Une alerte est alors inscrite dans warehouse/alertes.log (voir 5.2).

## Livrable 3 · Analyse technique du portefeuille

Ce livrable mesure la rentabilité technique du portefeuille, explique son évolution année par année et indique le degré de confiance à accorder à chaque chiffre. Tous les nombres viennent des marts de l'entrepôt.

### 3.1 Indicateurs techniques par axe

Les indicateurs sont calculés par produit, zone de risque, formule, canal de distribution et tranche d'âge, à partir de la table marts.indicateurs. Voici les définitions que nous avons posées avant de coder :

- **Sinistre retenu :** dossier au statut ouvert ou clôturé. Les dossiers sans suite et rejetés sont comptés à part.

- **Fréquence :** sinistres retenus ÷ années-police (jours couverts ÷ jours de l'année). Nous ne divisons jamais par le nombre de contrats : un contrat observé trois mois et un contrat observé cinq ans n'ont pas la même durée d'exposition.
- **Coût moyen :** règlements payés ÷ sinistres retenus.
- **Prime moyenne :** primes acquises ÷ années-police.
- **Ratio sinistres sur primes (S/P) :** règlements payés ÷ primes acquises. Le ratio « avec réserve » ajoute au numérateur la réserve restante des dossiers ouverts.
- **Taux de résiliation :** résiliations ÷ années-police.

NB : La colonne « Hors excep. » qui est ajouté ci-dessous donne le ratio sans le sinistre n° 1129 (auto, zone 4, formule Confort, canal agent, 40-59 ans, payé 2 475 975 €, soit 22,1 % de tous les paiements).

**Vue sur les tableaux + phrase actionnable :**

### Portefeuille total

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| Portefeuille | 4,33 | 5 735 | 442 | 56,1 | 58,8 | 14,5 | 43,7 |

**Action :** piloter le portefeuille avec le ratio hors sinistre exceptionnel (43,7 %) en plus du ratio brut (56,1 %), et le comparer au seuil d'alerte de travail de 70 %, afin qu'un seul dossier ne déclenche pas une fausse alerte.

### Par produit

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| AUTO | 4,42 | 7 191 | 589 | 53,9 | 56,3 | 14,6 | 35,8 |
| HABITATION | 4,24 | 4 128 | 287 | 60,9 | 64,1 | 14,4 | – |

**Action :** revoir en priorité le tarif de l'habitation : sa prime moyenne (287 €) est deux fois plus faible que celle de l'auto pour une fréquence proche, et son ratio (60,9 %) dépasse celui de l'auto .

### Par zone de risque

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| Zone 1 | 3,42 | 4 919 | 388 | 43,4 | 45,8 | 14,3 | – |
| Zone 2 | 4,04 | 4 567 | 424 | 43,5 | 45,5 | 14,5 | – |
| Zone 3 | 4,44 | 4 720 | 447 | 46,8 | 50,6 | 14,9 | – |
| Zone 4 | 4,73 | 9 683 | 482 | 94,9 | 96,5 | 14,7 | 37,3 |
| Zone 5 | 5,73 | 4 366 | 503 | 49,7 | 53,9 | 14,2 | – |

**Action :** conserver la tarification par zone, qui suit un risque réellement croissant (zone 1 contre zone 5 : $p < 0,0001$), et ne pas augmenter la prime de la zone 4 sur la base d'un seul dossier : son ratio de 94,9 % tombe à 37,3 % sans le litige exceptionnel.

### Par formule

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| CONFORT | 5,29 | 6 487 | 442 | 77,5 | 81,6 | 13,6 | 46,5 |

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| ESSENTIELLE | 2,66 | 6 068 | 371 | 43,5 | 44,7 | 17,0 | – |
| PREMIUM | 5,01 | 4 309 | 533 | 40,5 | 42,7 | 12,8 | – |

**Action :** promouvoir la formule Premium (ratio de 40,5 %, résiliation de 12,8 %) et engager une action de fidélisation sur l'Essentielle, dont la résiliation atteint 17,0 %.

### Par canal

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| AGENT | 4,32 | 7 976 | 444 | 77,6 | 80,7 | 12,0 | 48,1 |
| COURTIER | 4,29 | 4 015 | 442 | 39,0 | 40,8 | 12,4 | – |
| WEB | 4,36 | 4 197 | 441 | 41,5 | 44,2 | 18,5 | – |

**Action :** renforcer la rétention du canal web (résiliation de 18,5 % contre 12,0 % pour l'agent, écart significatif). Le ratio de l'agent (77,6 %) et son coût moyen élevé viennent d'un seul dossier (48,1 % sans lui).

### Par tranche d'âge

| Modalité | Fréq. % | Coût moyen € | Prime moy. € | Ratio S/P % | Avec réserve % | Résil. % | Hors excep. % |
|---|---|---|---|---|---|---|---|
| 25-39 ans | 4,08 | 4 063 | 425 | 38,9 | 41,7 | 14,4 | – |
| 40-59 ans | 4,20 | 7 451 | 430 | 72,8 | 74,9 | 14,5 | 46,1 |
| 60 ans et + | 4,13 | 4 621 | 442 | 43,2 | 46,2 | 14,4 | – |
| < 25 ans | 6,39 | 3 967 | 581 | 43,7 | 46,2 | 15,5 | – |
| Inconnu | 5,21 | 4 458 | 455 | 51,0 | 66,8 | 15,6 | – |

**Action :** vérifier que la tarification des moins de 25 ans tient compte de leur fréquence plus élevée (6,39 %) et ajuster la prime si l'écart n'est pas déjà couvert. Le ratio des 40-59 ans (72,8 %) retombe à 46,1 % sans le dossier exceptionnel.

### Règlements payés, réserves et sinistres sans suite

| Produit | Retenus | Payé € | Réserve € | Sans suite | Rejetés |
|---|---|---|---|---|---|
| AUTO | 1 026 | 7 377 811 | 332 342 | 215 | 398 |
| HABITATION | 930 | 3 839 023 | 199 353 | 150 | 80 |
| TOTAL | 1 956 | 11 216 834 | 531 695 | 365 | 478 |

Le payé (11,22 M€) est la somme des règlements. La réserve restante (0,53 M€) est ce qu'il reste à payer sur les dossiers ouverts, soit max(réserve initiale − payé, 0). Elle explique l'écart entre le ratio payé (56,1 %) et le ratio avec réserve (58,8 %). Les 365 dossiers sans suite et les 478 rejetés n'entrent ni dans la fréquence ni dans le coût moyen. Tous les rejetés sont en formule Essentielle.

## 3.2 Évolution annuelle et décomposition de la variation du ratio

Le ratio sinistres sur primes se décompose en trois facteurs :

ratio = fréquence × coût moyen ÷ prime moyenne

Le nombre de contrats n'apparaît pas dans cette formule : il agit autant sur les sinistres que sur les primes, donc il s'annule dans leur rapport. Il pèse sur les montants, pas sur le ratio. Seuls trois facteurs font donc bouger le ratio.

**Le premier tableau** ci-dessous donne, année par année, les primes, les règlements payés et le ratio, avec ses trois facteurs. Il montre ce qui s'est passé :

| Année | Primes € | Payé € | Ratio % | Fréq. % | Coût moyen € | Prime moy. € |
|---|---|---|---|---|---|---|
| 2020 | 823 904 | 495 994 | 60,2 | 5,24 | 5 113 | 445 |
| 2021 | 2 291 427 | 940 548 | 41,0 | 4,38 | 4 162 | 445 |
| 2022 | 3 577 692 | 1 866 940 | 52,2 | 4,71 | 4 913 | 443 |
| 2023 | 4 664 280 | 4 318 259 | 92,6 | 4,21 | 9 726 | 442 |
| 2024 | 5 585 261 | 2 730 961 | 48,9 | 4,23 | 5 105 | 442 |
| 2025 (6 mois) | 3 041 390 | 864 132 | 28,4 | 3,98 | 3 154 | 441 |

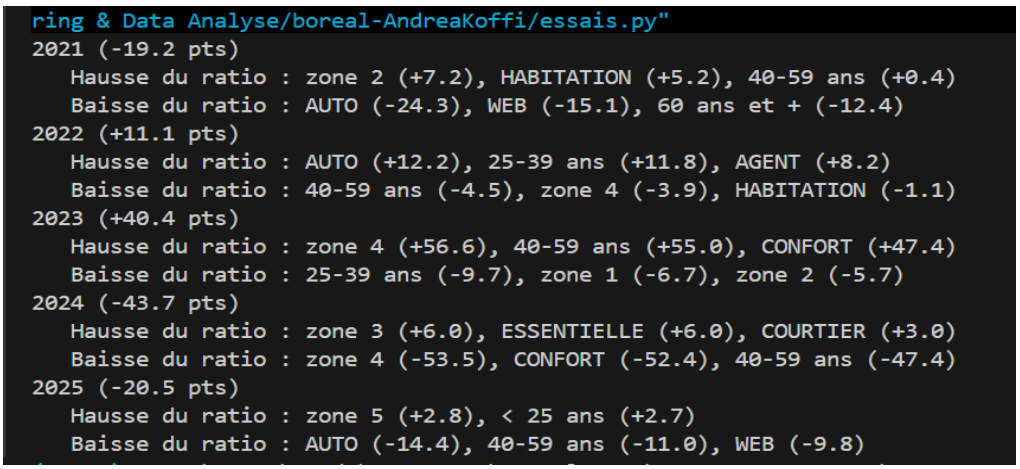
**Le second tableau** ci-dessous répartit la variation du ratio d'une année à l'autre, en points, entre ses causes. Il montre pourquoi le ratio a bougé. Exemple : en 2021, le ratio passe de 60,2 % à 41,0 %, soit −19,2 points .

| Année | Variation du ratio (pts) | Volume de contrats | Fréquence | Coût moyen | Prime moyenne |
|---|---|---|---|---|---|
| 2021 | −19,2 | 0,0 | −8,9 | −10,3 | 0,0 |
| 2022 | +11,1 | 0,0 | +3,3 | +7,7 | +0,2 |
| 2023 | +40,4 | 0,0 | −7,9 | +48,1 | +0,2 |
| 2024 | −43,7 | 0,0 | +0,4 | −44,1 | 0,0 |
| 2025 | −20,5 | 0,0 | −2,3 | −18,2 | 0,0 |

- **Volume de contrats :** effet nul sur le ratio, car sinistres et primes évoluent dans les memes proportions (par exemple +178 % de contrats et de primes en 2021)
- **En 2023 (+40,4 points) :** le coût moyen explique presque tout (+48,1 points). Le dossier exceptionnel y porte le ratio à 92,6 %, contre 39,5 % sans lui.
- **En 2024 (−43,7 points) :** le coût moyen revient à la normale (−44,1 points). La fréquence ne bouge presque pas (+0,4 point).

### Segments précis qui expliquent les hausses et les baisses

La contribution d'un segment est ses règlements divisés par les primes totales de l'année. Sa variation d'une année à l'autre s'exprime en points de ratio du portefeuille. Pour chaque axe, la somme des contributions est exactement la variation du ratio.




Le même dossier apparaît partout en 2023 et 2024 : la zone 4, le 40-59 ans et la formule Confort montent ensemble en 2023, puis redescendent ensemble en 2024. Ce n'est pas une dégradation de trois segments, mais l'effet d'un seul sinistre exceptionnel payé 2 475 975 € .

### Années incomplètes

- **2025 :** six mois seulement (jusqu'au 30 juin 2025) et 56,2 % des dossiers encore ouverts. Le ratio payé de 28,4 % monte à 44,5 % avec les réserves. L'année n'est pas comparable aux autres.
- **2024 :** presque complète (3,4 % de dossiers ouverts). Ratio de 48,9 % payé, 49,6 % avec réserve.
- **2020 :** année complète mais petite (1 852 années-police). Elle sert de référence à 2021, dont la baisse de 19,2 points est à lire avec prudence.

## 3.3 Rigueur statistique descriptive

### Intervalles de confiance

Un chiffre calculé sur un échantillon n'est jamais exact. L'intervalle de confiance (IC) à 95 % indique la zone où se trouve très probablement la vraie valeur : plus il est étroit, plus le chiffre est fiable. Nous donnons un IC pour chaque indicateur clé, avec la méthode adaptée à sa nature : la loi de Poisson exacte pour les événements comptés sur une exposition (sinistres, résiliations), l'intervalle de Wilson pour un pourcentage de clients, et le bootstrap pour les montants en euros, très inégaux (5 000 rééchantillonnages).

| Indicateur clé | Valeur | IC 95 % | Méthode |
|---|---|---|---|
| Fréquence de sinistres | 4,33 % | 4,14 – 4,53 | Poisson exact |
| Taux de résiliation | 14,54 % | 14,19 – 14,89 | Poisson exact |
| Coût moyen d'un sinistre | 5 734 € | 4 137 – 8 519 | Bootstrap (sinistres) |
| Coût moyen hors dossier exceptionnel | 4 471 € | 4 049 – 4 934 | Bootstrap (sinistres) |
| Prime moyenne | 442 € | 439 – 445 | Bootstrap (clients) |
| Ratio sinistres / primes | 56,1 % | 40,4 – 84,3 | Bootstrap (clients) |
| Rétention des multi-détenteurs à 4 ans | 75,1 % | 69,1 – 80,3 | Wilson |

La fréquence et la prime moyenne sont très précises. Le coût moyen et le ratio sinistres / primes le sont beaucoup moins : quelques sinistres très coûteux, dont un dossier de 2,48 M€, dominent les montants payés. Hors ce dossier, l'intervalle du coût moyen se resserre nettement. Le coût porte sur

1 957 sinistres, un de plus que la base technique (sinistre hors période d'exposition), d'où des écarts de quelques euros avec les tableaux de 3.1. L'intervalle du ratio est calculé sur la table clients, dont le montant payé diffère de 0,04 % de celui des marts.

**Deux comparaisons justifiées**

Pour savoir si un écart entre deux groupes est réel ou dû au hasard, nous utilisons un test : un résultat « p < 0,0001 » signifie que le hasard n'explique pratiquement pas l'écart.

| Comparaison | Test | Résultat | Conclusion |
|---|---|---|---|
| Fréquence, zone 1 contre zone 5 | Test binomial exact (deux taux de Poisson) | 3,42 % contre 5,73 %, p < 0,0001 | Écart significatif |
| Résiliation, WEB contre AGENT | Test binomial exact (deux taux de Poisson) | 18,47 % contre 12,03 %, p < 0,0001 | Écart significatif |
| Coût, WEB contre AGENT | Mann-Whitney (comparaison des rangs) | Médianes 1 728 € contre 1 876 €, p = 0,48 (0,50 hors dossier exceptionnel) | Pas de différence démontrée |

Pour les taux, nous testons si la part des événements d'un groupe est compatible avec sa part d'exposition. Pour les coûts, nous comparons les rangs plutôt que les moyennes, car un seul sinistre de 2,48 M€ dominerait un test sur les moyennes. La différence de coût moyen entre l'agent (7 976 €) et le web (4 197 €) n'est donc pas confirmée : elle repose sur un dossier. Ces tests montrent que les écarts existent, pas leur cause : ce sont des pistes à investiguer.

**Queue de la distribution des coûts**

| Indicateur | Valeur |
|---|---|
| Médiane | 1 814 € |
| Coût moyen | 5 734 € (3,2 fois la médiane) |
| Quantile 75 % / 90 % | 4 660 € / 10 356 € |
| Quantile 95 % / 99 % | 15 688 € / 42 752 € |
| Maximum | 2 475 975 € |
| Part des paiements des 1 % de sinistres les plus chers (20) | 35,2 % |
| Part des paiements des 5 % les plus chers (98) | 51,9 % |
| Part des paiements des 10 % les plus chers (196) | 63,0 % |
| Part du plus gros sinistre | 22,1 % |

Le coût est très concentré : 1 % des sinistres porte plus d'un tiers des paiements, et le plus gros dossier en représente à lui seul 22,1 %. C'est ce qui explique les intervalles larges du coût moyen et du ratio sinistres / primes. Nous présentons donc les indicateurs de coût avec et sans ce dossier, et nous suivons la médiane (1 814 €) autant que la moyenne.

## Livrable 4 · Analyse clients et gestion des sinistres

Après l'analyse du portefeuille, nous regardons les clients : combien de temps ils restent, ce qu'ils rapportent, et si les sinistres sont gérés dans des délais acceptables.

### 4.1 Cohortes par produit et multi-détention

### Matrices de rétention par cohorte de souscription

Une cohorte est l'ensemble des contrats souscrits la même année. Nous suivons, pour chaque cohorte, la part des contrats encore en vigueur au 31 décembre de l'année de souscription (k = 0), puis un an plus tard (k = 1), deux ans plus tard (k = 2), et ainsi de suite.

**Population et période.** Les tableaux portent sur les contrats, par produit, hors les 51 contrats en quarantaine. Nous ne calculons une case que si l'année est entièrement observée, c'est-à-dire si cohorte + k ≤ 2024. Les données s'arrêtent au 30 juin 2025 : 2025 est incomplète, et une rétention calculée sur six mois serait trop optimiste. C'est pourquoi la matrice est triangulaire. La cohorte 2025 n'est pas analysée.

**Auto : contrats encore en vigueur au 31/12 de (cohorte + k), en %**

| Cohorte | Contrats | k = 0 | k = 1 | k = 2 | k = 3 | k = 4 |
|---|---|---|---|---|---|---|
| 2020 | 2 060 | 92,0 | 79,2 | 68,4 | 57,7 | 51,0 |
| 2021 | 1 927 | 93,7 | 80,9 | 68,9 | 59,7 | – |
| 2022 | 2 003 | 93,8 | 80,5 | 70,9 | – | – |
| 2023 | 1 904 | 93,5 | 80,1 | – | – | – |
| 2024 | 2 009 | 93,6 | – | – | – | – |

**Habitation : contrats encore en vigueur au 31/12 de (cohorte + k), en %**

| Cohorte | Contrats | k = 0 | k = 1 | k = 2 | k = 3 | k = 4 |
|---|---|---|---|---|---|---|
| 2020 | 1 860 | 92,7 | 79,8 | 69,8 | 60,7 | 52,8 |
| 2021 | 1 847 | 92,3 | 79,3 | 68,4 | 58,9 | – |
| 2022 | 1 935 | 94,2 | 79,1 | 68,1 | – | – |
| 2023 | 1 848 | 93,2 | 81,0 | – | – | – |
| 2024 | 1 868 | 93,4 | – | – | – | – |

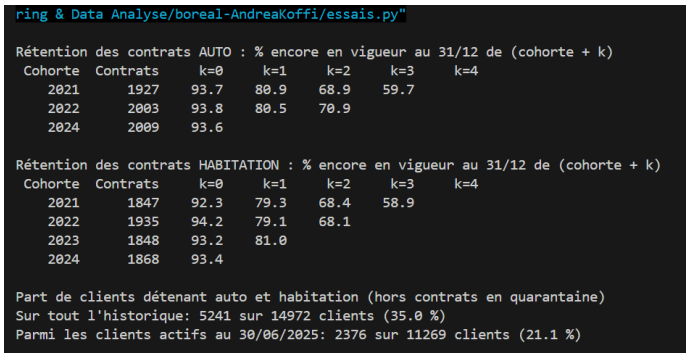



*Figure 11 : matrices de rétention auto et habitation, et part de clients multi-détenteurs (sortie de notre script d'analyse)*

Lecture : sur les 2 060 contrats auto souscrits en 2020, 92,0 % sont encore en vigueur fin 2020, 79,2 % fin 2021 et 51,0 % fin 2024. Les cohortes se ressemblent beaucoup : environ 93 % de rétention la première année, puis une perte de 12 à 13 points par an pendant deux ans, qui se ralentit ensuite (7 à 10 points). Il n'y a pas de différence nette entre l'auto et l'habitation.

**Action :** la perte est surtout concentrée sur les deux premières années (de 93 % à environ 69 %). C'est là qu'une action de fidélisation (appel après six mois, offre à l'anniversaire du contrat) a le plus de chances de payer.

### Clients multi-détenteurs et mono-détenteurs

Parmi les 14 972 clients ayant au moins un contrat retenu, 5 241 ont détenu à la fois un contrat auto et un contrat habitation, soit 35,0 %. Mais beaucoup ont résilié l'un des deux : parmi les 11 269 clients encore actifs au 30 juin 2025, 2 376 détiennent les deux produits, soit 21,1 %.

**Comment nous les comparons.** Nous classons chaque client dans la cohorte de son premier contrat. Il est « multi » s'il détient les deux produits dès la fin de son année de souscription, « mono » sinon. Il est « retenu » à l'année k s'il a encore au moins un contrat en vigueur au 31 décembre de (cohorte + k). Cette définition regarde la situation du client à son arrivée, et non son futur : elle évite de compter parmi les multi-détenteurs des clients qui n'ont pris un second contrat que parce qu'ils étaient déjà fidèles.

| Clients | k=0 n | % | k=1 n | % | k=2 n | % | k=3 n | % | k=4 n | % |
|---|---|---|---|---|---|---|---|---|---|---|
| MULTI (auto + habitation) | 987 | 99,5 | 798 | 95,7 | 618 | 91,3 | 410 | 82,2 | 225 | 75,1 |
| MONO | 13 500 | 93,2 | 11 512 | 82,2 | 9 210 | 76,2 | 6 506 | 71,0 | 3 470 | 67,7 |

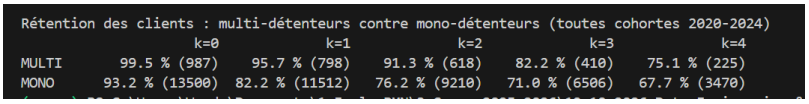



*Figure 12 : rétention des clients multi-détenteurs et mono-détenteurs, toutes cohortes 2020-2024*

Après quatre ans, 75,1 % des multi-détenteurs sont encore clients, contre 67,7 % des mono-détenteurs. L'intervalle de confiance à 95 % est de 69,1 à 80,3 % pour les multi (225 clients) et de 66,1 à 69,2 % pour les mono (3 470 clients) : les intervalles ne se recouvrent pas, l'écart est donc réel. L'écart est encore plus net à un an (95,7 % contre 82,2 %).

**NB :** Cela ne prouve pas que vendre un second contrat fait rester le client. Les clients qui prennent deux produits d'emblée sont peut-être déjà plus attachés à Boréal. Les multi-détenteurs sont aussi peu nombreux (987 en première année), donc les cases des dernières années reposent sur de petits effectifs.

**Action :** faire du second produit un objectif de la première année : un client qui arrive avec auto et habitation reste en moyenne plus longtemps.

### 4.2 Valeur observée des clients

La valeur observée d'un client est la somme de ses primes acquises moins la somme des sinistres payés sur ses contrats, depuis son arrivée jusqu'au 30 juin 2025. C'est une valeur observée, pas une valeur future : elle ne dit rien de ce que le client rapportera demain, et elle ne tient pas compte des frais de gestion. Les contrats en quarantaine sont exclus.

| Indicateur | Valeur | Lecture |
|---|---|---|
| Clients avec au moins un contrat retenu | 14 972 | Hors 28 clients sans contrat valide |
| Primes acquises | 19 983 953 € | Même total que le dashboard |
| Sinistres payés | 11 221 001 € | Tous les règlements des contrats retenus |
| Valeur observée totale | 8 762 952 € | Primes acquises moins sinistres payés |
| Valeur médiane d'un client | 932 € | La moitié des clients rapporte plus |
| Clients à valeur négative | 1 009 (6,7 %) | Ils ont coûté plus qu'ils n'ont rapporté |

| Indicateur | Valeur | Lecture |
|---|---|---|
| Clients ayant eu au moins un sinistre | 1 708 (11,4 %) | 89 % des clients n'ont jamais déclaré |

Nous retrouvons exactement les primes acquises du dashboard (19 983 953 €). Le total payé est supérieur de 4 167 € (0,04 %) à celui du Livrable 3 car nous comptons ici tous les règlements du client, sans restreindre aux sinistres retenus dans la période d'exposition.

### Concentration de la valeur

| Groupe de clients (classés du plus au moins rentable) | Part de la valeur nette | Lecture |
|---|---|---|
| Les 10 % les plus rentables | 58,1 % | 1 497 clients |
| Les 20 % les plus rentables | 97,3 % | 2 994 clients |
| Les 10 % les moins rentables | −101,9 % | Leur perte cumulée dépasse la valeur nette du portefeuille |

La courbe de concentration (page « Technique et clients » du dashboard) classe les clients du plus au moins rentable et cumule leur valeur. Elle monte vite, dépasse 100 % puis retombe : les clients les moins rentables effacent une partie de ce que les autres rapportent. Les 20 % de clients les plus rentables produisent à eux seuls 97 % de la valeur nette, et les 10 % les moins rentables perdent l'équivalent de 102 % de la valeur nette.

NB : plus du quart de cette perte (2,47 M€ sur les 8,93 M€ perdus par les 10 % les moins rentables) vient d'un seul client, le titulaire du contrat 5723 (client 8256), dont le sinistre exceptionnel a coûté 2 475 975 € pour 2 812 € de primes. Sans lui, la valeur nette du portefeuille serait de 11,2 M€ au lieu de 8,8 M€.

### Qui sont les clients les plus et les moins rentables ?

| Profil moyen | 10 % les plus rentables | 10 % les moins rentables | Ensemble |
|---|---|---|---|
| Prime acquise par client | 3 448 € | 1 124 € | 1 335 € |
| Sinistres payés par client | 45 € | 7 086 € | 749 € |
| Valeur par client | +3 403 € | −5 962 € | +585 € |
| Années-police par client | 6,13 | 2,51 | – |
| Nombre moyen de produits | 1,68 | 1,32 | 1,35 |
| Part ayant déclaré un sinistre | 6,7 % | 70,3 % | 11,4 % |

- **Les plus rentables** sont des clients qui restent longtemps (6 années-police en moyenne), qui détiennent plus souvent les deux produits et qui déclarent très rarement un sinistre (6,7 %). Leur valeur vient d'abord de leurs primes cumulées.
- **Les moins rentables** ont en moyenne peu d'années de primes (2,5 années-police) et sont ceux dont un sinistre a coûté beaucoup plus que leurs primes : sept sur dix ont déclaré au moins un sinistre, pour un montant moyen payé de 7 086 €. Le sinistre est la cause, pas le profil : il n'y a pas de tranche d'âge qui perde systématiquement de l'argent.
- **Par tranche d'âge,** la valeur moyenne par client est de 354 € pour les 40-59 ans (le dossier exceptionnel y pèse), contre 757 € pour les 60 ans et plus, 781 € pour les 25-39 ans et 975 €

pour les moins de 25 ans. La part de clients à valeur négative est à peu près la même partout (de 6,1 % à 8,3 %).

**Action :** ne pas cibler des clients « à risque » sur leur profil (âge, région), mais sur le comportement observé : un client qui déclare tôt un gros sinistre dans sa vie de contrat mérite un suivi particulier.

### 4.3 Délais, audits et fraude

#### Délais de gestion des sinistres par garantie

Nous mesurons trois délais, en jours, avec leur médiane et leurs quantiles. Un quantile à 90 % de 114 jours signifie que 9 dossiers sur 10 sont traités en 114 jours ou moins.

- **Délai de déclaration :** de la survenance du sinistre à sa déclaration. 2 790 sinistres, soit les 2 805 moins 15 dossiers dont la date de déclaration est antérieure à la survenance (règle Q20, signalés).
- **Délai de premier règlement :** de la déclaration au premier paiement. 1 858 sinistres ont été payés (les 1 785 clôturés et 73 des 173 ouverts). Les 482 rejetés et les 365 sans suite n'ont aucun paiement.
- **Délai de clôture :** aucune date de clôture n'existe dans les sources. Nous l'approchons par la date du dernier règlement des dossiers clôturés (1 785 dossiers), de la déclaration à ce dernier paiement. C'est une limite : un dossier peut être clôturé après son dernier paiement.

#### Délai de déclaration (en jours)

| Garantie | Dossiers | Médiane | 75 % | 90 % | 95 % | Maximum |
|---|---|---|---|---|---|---|
| BRIS_GLACE | 335 | 6 | 12 | 19 | 27 | 65 |
| COLLISION | 693 | 5 | 11 | 20 | 30 | 64 |
| DEGAT_EAUX | 589 | 5 | 11 | 19 | 28 | 72 |
| INCENDIE | 108 | 6 | 11 | 23 | 34 | 48 |
| RC | 444 | 5 | 11 | 18 | 24 | 74 |
| TEMPETE | 235 | 4 | 10 | 17 | 22 | 37 |
| VOL | 386 | 5 | 11 | 25 | 38 | 65 |
| Toutes garanties | 2 790 | 5 | 11 | 20 | 29 | 74 |

#### Délai de premier règlement après déclaration (en jours)

| Garantie | Dossiers | Médiane | 75 % | 90 % | 95 % | Maximum |
|---|---|---|---|---|---|---|
| BRIS_GLACE | 69 | 45 | 79 | 106 | 131 | 204 |
| COLLISION | 396 | 50 | 80 | 118 | 133 | 387 |
| DEGAT_EAUX | 476 | 52 | 84 | 117 | 141 | 287 |
| INCENDIE | 104 | 47 | 76 | 133 | 149 | 226 |
| RC | 409 | 50 | 78 | 108 | 135 | 208 |
| TEMPETE | 114 | 54 | 81 | 139 | 175 | 259 |
| VOL | 290 | 46 | 75 | 108 | 127 | 231 |
| Toutes garanties | 1 858 | 49 | 80 | 114 | 139 | 387 |

### Délai de clôture, approché par le dernier règlement (en jours)

| Garantie | Dossiers | Médiane | 75 % | 90 % | 95 % | Maximum |
|---|---|---|---|---|---|---|
| BRIS_GLACE | 64 | 93 | 142 | 243 | 269 | 283 |
| COLLISION | 382 | 80 | 144 | 209 | 258 | 542 |
| DEGAT_EAUX | 464 | 88 | 139 | 223 | 264 | 464 |
| INCENDIE | 99 | 76 | 146 | 189 | 228 | 359 |
| RC | 391 | 89 | 138 | 202 | 228 | 454 |
| TEMPETE | 110 | 84 | 143 | 221 | 264 | 359 |
| VOL | 275 | 72 | 139 | 203 | 230 | 504 |
| Toutes garanties | 1 785 | 83 | 141 | 208 | 253 | 542 |

Les clients déclarent rapidement (médiane de 5 jours, 90 % en 20 jours). Le premier paiement arrive après 49 jours en médiane, mais 10 % des dossiers attendent plus de 114 jours, et la queue est longue (maximum de 387 jours). Les garanties se ressemblent : les écarts entre garanties sont faibles devant la dispersion à l'intérieur de chacune. La tempête a le 90 % le plus long (139 jours), mais ses 114 dossiers rendent cet écart fragile.

**Action :** fixer un délai cible de premier règlement (par exemple 90 jours) et suivre chaque mois la part de dossiers qui le dépassent. Aujourd'hui, 18,9 % des dossiers payés le dépassent.

### Taux de confirmation de fraude

**À qui s'applique ce chiffre ?** Les 372 audits portent sur 372 sinistres : 336 clôturés, 20 sans suite et 16 ouverts. Ce n'est pas un échantillon tiré au hasard : les dossiers audités ont été choisis par le service antifraude. Le taux de confirmation de 9,9 % (37 fraudes sur 372 audits, intervalle de 7,3 à 13,4 %) vaut donc uniquement pour les dossiers audités. Il ne mesure pas le taux de fraude du portefeuille, qui est inconnu.

| Critère d'audit | Audités | Fraudes confirmées | Taux de confirmation | Intervalle à 95 % |
|---|---|---|---|---|
| Tous les dossiers audités | 372 | 37 | 9,9 % | 7,3 – 13,4 % |
| AUTO | 204 | 20 | 9,8 % | 6,4 – 14,7 % |
| HABITATION | 168 | 17 | 10,1 % | 6,4 – 15,6 % |
| Canal AGENT | 164 | 20 | 12,2 % | 8,0 – 18,1 % |
| Canal COURTIER | 69 | 6 | 8,7 % | 4,0 – 17,7 % |
| Canal WEB | 139 | 11 | 7,9 % | 4,5 – 13,6 % |
| Formule CONFORT | 173 | 22 | 12,7 % | 8,5 – 18,5 % |
| Formule ESSENTIELLE | 84 | 7 | 8,3 % | 4,1 – 16,2 % |
| Formule PREMIUM | 115 | 8 | 7,0 % | 3,6 – 13,1 % |
| Garantie VOL | 59 | 12 | 20,3 % | 12,0 – 32,3 % |
| Garantie COLLISION | 66 | 9 | 13,6 % | 7,3 – 23,9 % |
| Garantie RC | 106 | 2 | 1,9 % | 0,5 – 6,6 % |
| Garantie BRIS_GLACE | 13 | 4 | 30,8 % | 12,7 – 57,6 % |
| Garantie TEMPETE | 11 | 0 | 0,0 % | 0,0 – 25,9 % |

Selon les critères disponibles, la confirmation est plus fréquente sur le vol (20,3 %) et la collision (13,6 %) que sur la responsabilité civile (1,9 %), et un peu plus fréquente dans le canal agent (12,2 %) et la formule Confort (12,7 %) que dans le web (7,9 %) ou la formule Premium (7,0 %). Les intervalles montrent que seuls les écarts du vol et de la collision face à la responsabilité civile sont solides : les autres écarts sont dans la marge d'erreur. Les garanties bris de glace (13 audits) et tempête (11 audits) ont trop peu d'audits pour conclure.

#### L'intérêt des audits au regard des montants

Nous évaluons l'intérêt des audits de façon descriptive :

- **Les audits visent les gros dossiers.** Parmi les dossiers clôturés, 18,8 % sont audités (336 sur 1 785). Un dossier clôturé audité a coûté 18 639 € en moyenne (médiane 7 416 €), contre 3 228 € (médiane 1 609 €) pour un dossier non audité. Les 372 dossiers audités concentrent 6,43 M€ de paiements, soit 57 % du total.
- **Ce que les fraudes confirmées représentent.** Les 37 fraudes confirmées correspondent à 487 280 € payés (13 170 € en moyenne, médiane 4 380 €), soit 4,3 % de tous les paiements et 7,6 % des paiements des dossiers audités. C'est l'ordre de grandeur de ce que les audits permettent d'identifier, et d'éviter à l'avenir si la fraude est détectée avant paiement.
- **Le sinistre exceptionnel a été audité, et la fraude n'a pas été confirmée.** Le dossier 1129 (2,48 M€) est dans les 372 audits, sans fraude confirmée. Il pèse 38 % des paiements des dossiers audités : sans lui, ceux-ci représentent 3,96 M€.

| Montant payé du dossier clôturé | Dossiers clôturés | Part auditée | Fraudes confirmées | Taux de confirmation |
|---|---|---|---|---|
| Moins de 1 000 € | 539 | 6,7 % | 4 sur 36 | 11,1 % |
| 1 000 à 5 000 € | 797 | 5,9 % | 9 sur 47 | 19,1 % |
| 5 000 à 10 000 € | 250 | 55,2 % | 11 sur 138 | 8,0 % |
| 10 000 € et plus | 199 | 57,8 % | 6 sur 115 | 5,2 % |

Ce dernier tableau est le plus parlant. Les audits se concentrent sur les dossiers de plus de 5 000 € (plus de la moitié sont audités), où le taux de confirmation est le plus faible (de 5,2 % à 8,0 %). À l'inverse, les dossiers de 1 000 à 5 000 € sont très rarement audités (5,9 %), alors que 9 audits sur 47 y ont confirmé une fraude (19,1 %). L'effectif est petit, donc il s'agit d'une piste et non d'une preuve.

**Action :** tester un échantillon d'audits plus large sur les dossiers de 1 000 à 5 000 €, où la part de fraude confirmée est la plus élevée, et évaluer son rendement avant de généraliser.

## Livrable 5 · Dashboard, exploitation et documentation

Ce dernier livrable rend la chaîne utilisable au quotidien : un tableau de bord pour la directrice, un pipeline qui se lance seul, une documentation qui permet à quelqu'un d'autre de le refaire.

### 5.1 Dashboard interactif

Nous avons développé le dashboard avec Streamlit (fichier app.py). Il n'interroge que les tables du schéma marts, en lecture seule : il ne lit jamais les fichiers sources ni la préparation, et ne recalcule aucun indicateur. Ses chiffres sont donc ceux du dossier. C'est un choix de cohérence : une seule source de vérité, calculée une seule fois.

Le dashboard se charge en quelques secondes, parce qu'il lit seulement ces petites tables déjà calculées. Il offre quatre onglets : trois pages demandées par le sujet et une page de définitions.

**Page 1 · Portefeuille : « où le portefeuille gagne ou perd de l'argent ? ».**

Cette page montre six chiffres clés (primes acquises 19 983 953 €, contrats actifs 13 798, ratio sinistres sur primes 56,1 %, fréquence 4,33 %, coût moyen 5 735 €, résiliation 14,5 %), identiques à ceux du Livrable 3. En dessous, le ratio mensuel est comparé à l'année précédente, avec un bandeau vert ou rouge selon le seuil d'alerte. Les trois derniers mois sont signalés comme immatures (ratio sous-estimé) et peuvent être exclus d'un clic. Le graphique de marge technique par segment (primes moins sinistres payés, avant frais) montre que l'auto rapporte le plus (6,3 M€) et l'habitation le moins (2,5 M€). Le dernier graphique indique ce qui fait bouger le ratio par rapport à la même période de l'an dernier.

**Page 2 · Technique et clients**

Cette page regroupe le ratio par zone, formule, canal et tranche d'âge (avec une ligne rouge à 70 %), la décomposition de l'évolution du ratio en points (fréquence, coût moyen, prime moyenne), la matrice de rétention par cohorte et la courbe de concentration de la valeur client avec le nombre de clients à valeur négative. Elle reprend les résultats des Livrables 3 et 4.

**Page 3 · Exploitation**

C'est le poste de contrôle de la chaîne : fraîcheur des données (30/06/2025), dernier chargement par source, résultats des tests (19 sur 19), lignes rejetées par règle de qualité, et délais de gestion des sinistres par garantie (médiane et quantile à 90 %, pour chacune des trois étapes). Si un test échoue, le bandeau passe au rouge.

**Page 4 · Définition**

Explique chaque indicateur en une phrase (numérateur, dénominateur, période, population), ainsi que le seuil d'alerte.

### 5.2 Orchestration, alertes et documentation

**Un pipeline qui se lance seul**

La commande unique python **pipeline/run_all.py** exécute les sept étapes dans l'ordre. Chaque étape est un petit script autonome, que l'on peut aussi lancer seul pour comprendre ou déboguer :

| # | Étape | Commande exécutée | Rôle |
|---|---|---|---|
| 1 | Chargement des sources (brut) | python pipeline/ingest.py [--mois AAAA_MM] | Copie fidèle des fichiers, journal d'ingestion |
| 2 | Tests du brut | python tests/test_brut.py | 6 tests, dont le rejeu sans doublon |
| 3 | Préparation | python pipeline/run_sql.py 02_prep | Types, dates, montants unifiés |
| 4 | Contrôles de qualité | python pipeline/qualite.py | 23 règles, quarantaine, registre |
| 5 | Cœur | python pipeline/run_sql.py 03_core | Déduplication, dimensions et faits |
| 6 | Tests du cœur | python tests/test_coeur.py | 13 tests bloquants |
| 7 | Marts | python pipeline/run_sql.py 04_marts | Indicateurs lus par le dashboard |

Un test en échec arrête immédiatement la chaîne : les étapes suivantes (cœur puis marts) ne sont pas exécutées, donc le Dashboard continue d'afficher les derniers chiffres validés.

**Exécution déclenchée par l'arrivée d'un nouveau fichier**

Nous avons écrit un script de surveillance, **pipeline/declencheur.py**. Il compare les fichiers de règlements présents dans le dossier des sources avec ceux déjà chargés dans l'entrepôt (colonne

_source_file de raw.reglements). Si un fichier mensuel est nouveau, il lance la chaîne complète ; sinon il ne fait rien. Une tâche planifiée de Windows l'exécute chaque jour à 6 h. L'exécution est donc déclenchée par l'événement. Nous avons testé le cas en supprimant le mois de mai 2025 du brut : le déclencheur le détecte comme nouveau et recharge exactement ce mois. La commande python ***pipeline/declencheur.py --une-fois*** permet de le démontrer en direct.

### Alertes en cas d'échec

- **Alerte écrite :** toute étape qui échoue ajoute une ligne datée dans warehouse/alertes.log, avec le nom de l'étape et le code d'erreur.
- **Journal complet :** chaque exécution est tracée dans warehouse/journal_pipeline.log (heure de début, étapes, durée).

Un fichier manquant ou un mois inexistant est refusé avant toute modification de l'entrepôt, avec un message lisible.

### README en cinq commandes

Le fichier README.md permet à quelqu'un qui n'a rien d'installé de tout reproduire. Après avoir déposé les sources dans data/sources :

```
py -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install -r requirements.txt
python pipeline/run_all.py
streamlit run app.py
```

Il explique aussi le rechargement d'un mois, la planification, les alertes et le contenu de chaque dossier.

### Catalogue des données et lignage

Le catalogue (catalogue.md) est généré automatiquement par ***pipeline/catalogue.py*** : il interroge l'entrepôt et liste chaque table et chaque colonne avec son type, sa définition et sa couche. Il est donc toujours en phase avec la base, sans mise à jour manuelle. Le schéma de lignage suit un indicateur, le ratio sinistres sur primes, depuis les fichiers sources jusqu'au graphique du dashboard.

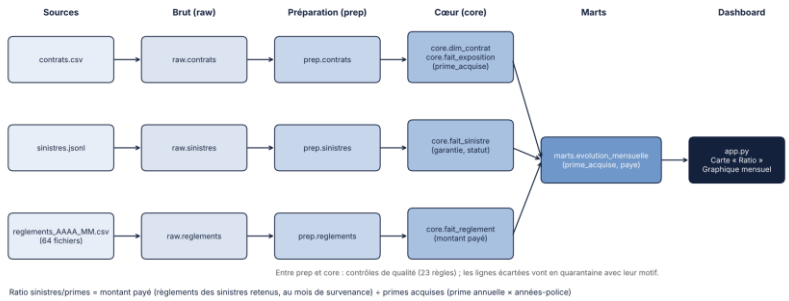



*Figure 14 : lignage du ratio sinistres sur primes, de la source au graphique mensuel*

Lecture : le montant payé vient des 64 fichiers de règlements et des sinistres retenus, les primes acquises viennent des contrats et de l'exposition. Les deux se rejoignent dans marts.evolution_mensuelle, que lit app.py. Entre la préparation et le cœur, les 23 règles de qualité écartent les lignes douteuses vers la quarantaine.

### Démonstration et reproductibilité

Le notebook, ***notebooks/demo_pipeline.ipynb***, rassembles en un seul document la démonstration, couche par couche, avec les chiffres réels de l'entrepôt : le brut et le rechargement d'un mois sans

doublon, la qualité et la quarantaine, le schéma en étoile, les 19 tests, les marts, l'exploitation, l'orchestration et le calcul du ratio sinistres sur primes.

### 5.3 Gouvernance et analyse RGPD

#### Quelles données personnelles et quel niveau de pseudonymisation ?

Boréal nous a livré des données pseudonymisées : ni nom ni adresse, seulement des identifiants et une empreinte d'e-mail. Pseudonymisé ne veut pas dire anonyme : la date de naissance, la région et la catégorie socioprofessionnelle peuvent suffire à reconnaître une personne, et l'empreinte d'e-mail peut être retrouvée par essais si elle n'est pas protégée par un secret. Ces données restent donc personnelles au sens du RGPD, dans toutes les couches. Les audits 'antifraude' demandent une vigilance particulière, car ils touchent à des soupçons d'infraction.

| Couche | Données personnelles | Pseudonymisation | Droit à l'effacement |
|---|---|---|---|
| Sources (archive) | Client : identifiant, date de naissance, région, CSP, consentement, empreinte d'e-mail ; le reste est lié par l'identifiant du client | Faite par Boréal : ni nom ni coordonnées | Traité à la source |
| Brut (raw) | Copie complète des sources | Identique | Suppression des lignes du client |
| Préparation (prep) et quarantaine | Mêmes champs ; identifiant et parfois date de naissance dans les motifs d'anomalie | Identique | Reconstruite depuis le brut ; purger les tables de qualité qui citent le client |
| Cœur (core) | dim_client : âge, tranche d'âge, région, CSP, consentement | Identifiant client conservé | Reconstruit depuis le brut |
| Marts | Agrégats, plus valeur_client (un identifiant par ligne) | Identifiant seulement | Reconstruits à la prochaine exécution |
| Dashboard | Aucune donnée individuelle | Sans objet | Sans objet ; surveiller les petits segments |
| Journal d'ingestion | Aucune | Sans objet | Sans objet |

#### Durée de conservation

Nous proposons les durées suivantes, à valider avec le délégué à la protection des données de Boréal. La règle générale est de ne pas garder une donnée plus longtemps que nécessaire à sa finalité.

| Type de données | Durée de conservation proposée | Justification |
|---|---|---|
| Clients et contrats | Durée du contrat, puis 5 ans | Prescription civile de droit commun : le temps où une contestation reste possible |
| Sinistres et règlements | Durée de gestion du dossier, puis 5 ans (davantage si un dommage corporel est en jeu) | Même raison, et suivi d'un éventuel recours |
| Audits antifraude | Plus courte, à fixer avec le délégué à la protection des données | Donnée sensible : elle touche à une infraction possible et expose la personne à un risque de fichage |
| Consentement marketing | Jusqu'au retrait du consentement ou à l'inactivité prolongée du client | Principe de limitation de la finalité |

**Droit à l'effacement : comment effacer un client dans chaque couche**

Un client qui demande l'effacement de ses données peut être supprimé de la chaîne en suivant l'ordre ci-dessous.

1. Supprimer le client à la source (hors du périmètre de l'entrepôt) et inscrire son identifiant dans une liste d'effacement.
2. Supprimer ses lignes du brut : le client, puis ses contrats, sinistres, règlements et audits, retrouvés grâce à l'identifiant.
3. Purger les tables de qualité (anomalies et quarantaine) qui citent son identifiant ou sa date de naissance.
4. Relancer la chaîne complète : la préparation, le cœur et les marts se reconstruisent depuis le brut et n'ont plus aucune trace du client.
5. Appliquer la liste d'effacement à chaque nouveau chargement, pour qu'un fichier rechargé ne fasse pas réapparaître la personne.

Deux précautions. D'abord, un contrat ou un sinistre peut devoir être conservé pour une obligation légale ou pour une action en justice : l'effacement n'est alors pas total, et on anonymise la ligne (on retire l'identifiant, la date de naissance, la région) au lieu de la supprimer. Ensuite, les sauvegardes de l'entrepôt contiennent encore le client jusqu'à leur renouvellement.

## Conclusion

Nous avons construit, de bout en bout, une chaîne de données qui répond au besoin de départ : une source unique de vérité, mise à jour sans intervention manuelle, et un tableau de bord dont les chiffres sont ceux du dossier. Sur le plan technique, la chaîne est reproductible en cinq commandes, idempotente, protégée par 19 tests qui l'arrêtent en cas d'échec, et traçable : 283 lignes en quarantaine avec leur motif, et chaque ligne du brut garde son fichier d'origine.

Sur le plan analytique, notre résultat principal est un constat de prudence. Le portefeuille est rentable (56,1 % de sinistres sur primes), mais un seul sinistre de 2,48 M€ suffit à déformer l'année 2023, la zone 4, le canal agent ou la formule Confort. C'est pourquoi nos tableaux donnent le chiffre avec et sans ce dossier. Les vrais leviers que nous identifions sont le tarif de l'habitation, la fidélisation dès la première année (un contrat sur deux est perdu après quatre ans) et le suivi des délais de règlement.

Nos limites, que nous disons clairement : pas de frais ni de commissions dans les sources (nos marges sont brutes, le seuil de 70 % est une hypothèse), année 2025 incomplète, dernier trimestre immature, date de clôture absente, taux de fraude valable seulement pour les dossiers audités. Nos analyses décrivent le passé, sans prévision ni preuve de causalité.

Les prochaines étapes seraient d'intégrer les frais de gestion pour obtenir un vrai ratio combiné et d'automatiser l'effacement RGPD. Ce projet nous a surtout appris qu'un chiffre n'a de valeur que si l'on sait d'où il vient, ce qu'il contient et à qui il s'applique.

## Annexes

**Annexe 1 · Glossaire**

Quelques termes utilisés dans ce dossier, expliqués simplement.

| Terme | Définition simple |
|---|---|
| Année-police | Une année de couverture d'un contrat. Un contrat couvert six mois compte 0,5 année-police. C'est le dénominateur de toute fréquence. |
| Exposition | Durée pendant laquelle un contrat couvre réellement le client, mesurée en années-police. |
| Prime acquise | Part de la prime annuelle qui correspond à la période déjà écoulée. Un contrat de 600 € couvert six mois a acquis 300 €. |
| Fréquence | Nombre de sinistres divisé par les années-police : à quelle vitesse les sinistres arrivent. |
| Coût moyen | Montant payé divisé par le nombre de sinistres retenus. |
| Ratio sinistres sur primes (S/P) | Sinistres payés divisés par les primes acquises. À 56 %, Boréal reverse 56 centimes de sinistres pour chaque euro de prime. |
| Marge technique | Primes acquises moins sinistres payés, avant frais de gestion et commissions. |
| Réserve | Somme que l'assureur met de côté pour payer un sinistre ouvert. |
| Sinistre retenu | Sinistre ouvert ou clôturé. Les dossiers rejetés et sans suite sont comptés à part. |
| Cohorte et rétention | Une cohorte regroupe les contrats souscrits la même année. La rétention est la part de ces contrats encore en vigueur plus tard. |
| Mois immature | Mois récent dont tous les sinistres ne sont pas encore déclarés : son ratio est sous-estimé. |
| Brut, préparation, cœur, marts | Les quatre couches de l'entrepôt : copie fidèle, données typées, schéma en étoile, indicateurs prêts à lire. |
| Quarantaine | Table où atterrit une ligne écartée, avec son motif. Rien n'est jamais supprimé sans trace. |
| Idempotence | Propriété d'une opération qui donne le même résultat qu'on la lance une ou plusieurs fois. |
| Grain | Ce que représente exactement une ligne d'une table de faits (par exemple un contrat pour une année). |
| Intervalle de confiance | Fourchette dans laquelle se trouve très probablement la vraie valeur, à 95 %. |
| Pseudonymisation | Remplacement des données qui identifient directement une personne (nom, e-mail) par un code. Elle n'empêche pas toujours la ré-identification. |

## Annexe 2 · Règles de qualité

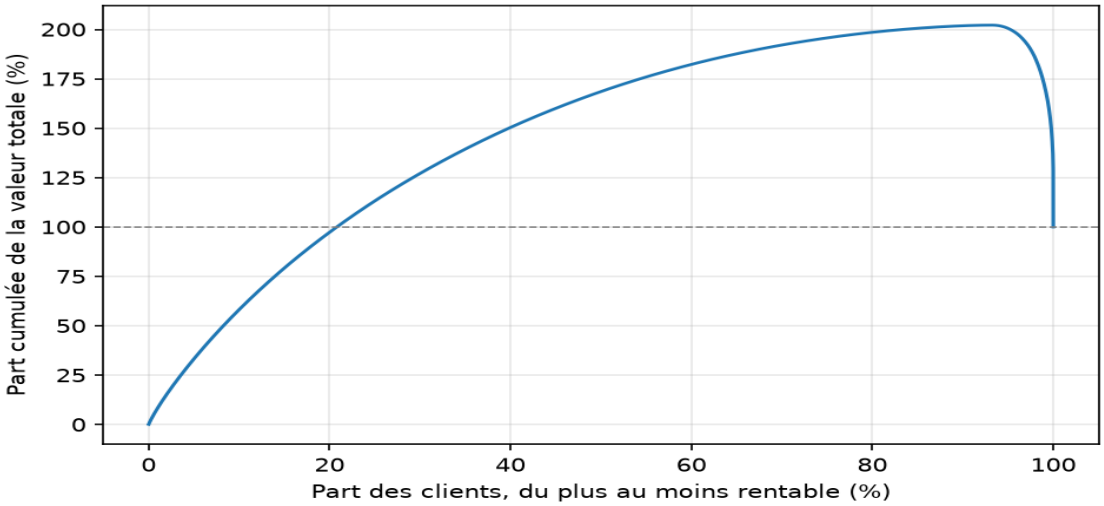
| Id | Famille | Règle | Gravité | Volume | Traitement |
|---|---|---|---|---|---|
| Q01 | Complétude | Date de naissance absente | Mineure | 226 | Signaler |
| Q02 | Complétude | Date d'effet du contrat absente | Bloquante | 0 | Exclure |
| Q03 | Complétude | Montant du règlement absent | Bloquante | 0 | Exclure |
| Q04 | Unicité | Client en double (même email_hash) : on écarte les non-survivants | Majeure | 200 | Corriger |
| Q05 | Unicité | Identifiant de contrat dupliqué | Bloquante | 0 | Exclure |
| Q06 | Unicité | Identifiant de sinistre dupliqué | Bloquante | 0 | Exclure |
| Q07 | Unicité | Paiement rejoué dans un fichier d'un autre mois : on écarte la copie hors mois | Majeure | 32 | Exclure |
| Q08 | Validité | Prime annuelle nulle ou négative | Majeure | 25 | Exclure |
| Q09 | Validité | Date de naissance antérieure à 1920 | Mineure | 18 | Signaler |
| Q10 | Validité | Titulaire mineur à la date d'extraction | Majeure | 22 | Signaler |
| Q11 | Validité | Montant de règlement nul ou négatif | Bloquante | 0 | Exclure |

| Id | Famille | Règle | Gravité | Volume | Traitement |
|---|---|---|---|---|---|
| Q12 | Validité | Valeur hors domaine (produit, formule, canal, statut, garantie) | Majeure | 0 | Signaler |
| Q13 | Validité | Réserve initiale extrême (supérieure à 1 000 000 euros) | Majeure | 1 | Signaler |
| Q14 | Cohérence entre tables | Contrat rattaché à un client inexistant | Bloquante | 0 | Exclure |
| Q15 | Cohérence entre tables | Sinistre rattaché à un contrat inexistant | Bloquante | 0 | Exclure |
| Q16 | Cohérence entre tables | Règlement rattaché à un sinistre inexistant | Bloquante | 0 | Exclure |
| Q17 | Cohérence entre tables | Garantie incompatible avec le produit du contrat | Majeure | 0 | Signaler |
| Q18 | Cohérence entre tables | Règlement versé sur un sinistre rejeté ou sans suite | Majeure | 0 | Signaler |
| Q19 | Cohérence temporelle | Résiliation antérieure ou égale à la date d'effet (exposition nulle ou négative) | Bloquante | 26 | Exclure |
| Q20 | Cohérence temporelle | Déclaration antérieure à la survenance du sinistre | Majeure | 15 | Signaler |
| Q21 | Cohérence temporelle | Sinistre survenu hors période de couverture du contrat | Majeure | 18 | Signaler |
| Q22 | Cohérence temporelle | Règlement antérieur à la survenance du sinistre | Majeure | 0 | Signaler |
| Q23 | Cohérence temporelle | Date postérieure à la date d'extraction (30/06/2025) | Majeure | 0 | Signaler |

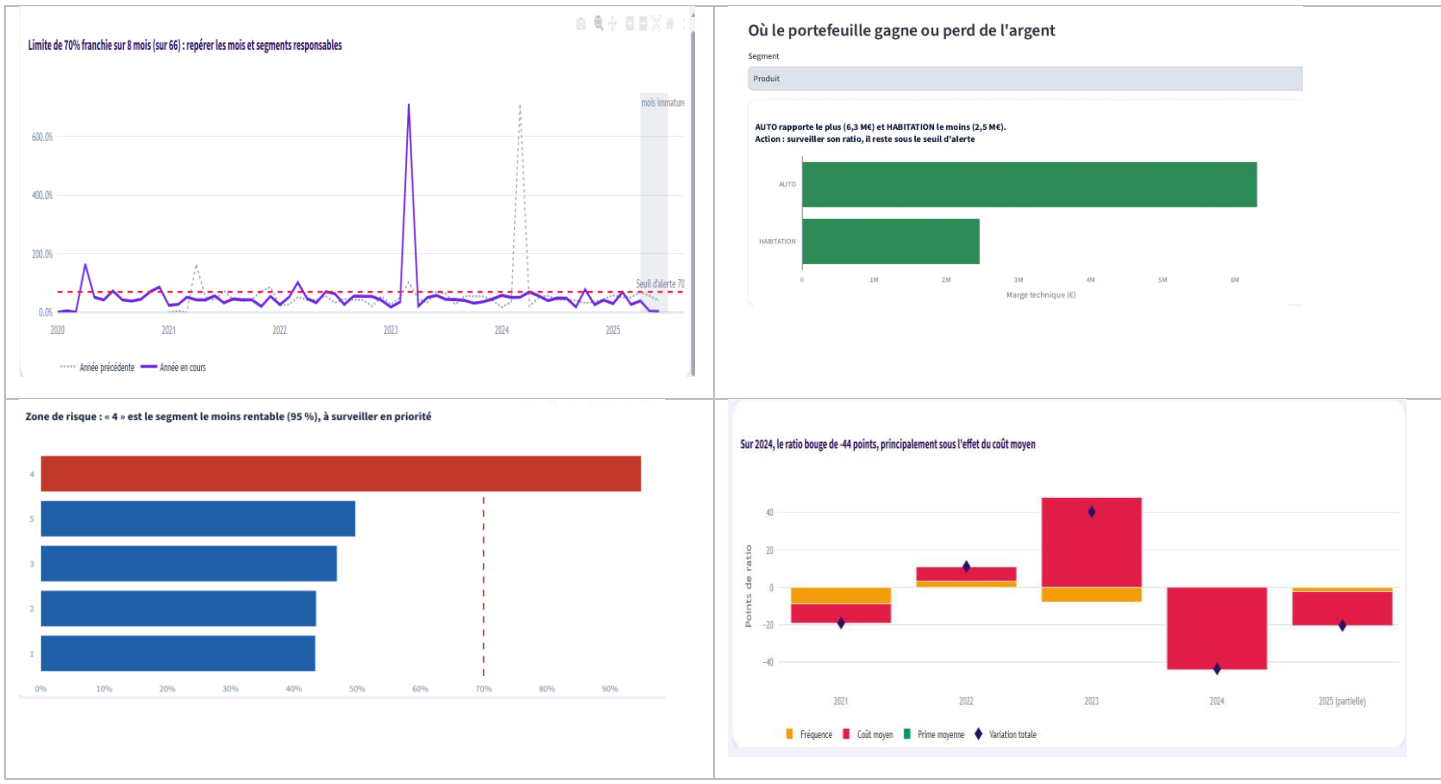
## Annexe 3 · Table dans marts (calcul indicateur)

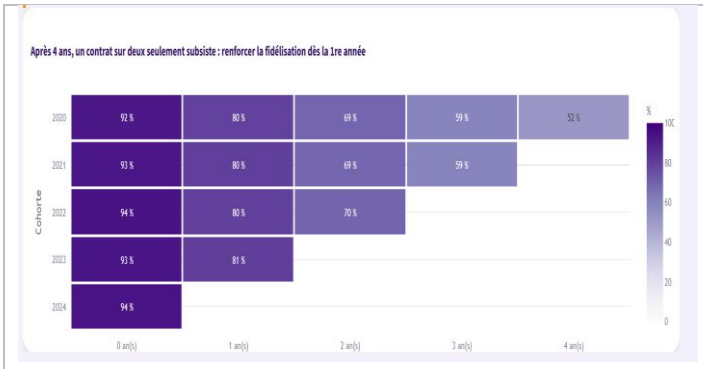
| Table (schéma marts) | Rôle |
|---|---|
| base_technique | Une ligne par année et par combinaison de segments (produit, zone, formule, canal, tranche d'âge) : exposition, prime acquise, sinistres retenus, payé, réserve. Socle de tous les indicateurs |
| indicateurs | Fréquence, coût moyen, prime moyenne, ratio et résiliation par produit, zone, formule, canal et tranche d'âge |
| evolution_annuelle | Décomposition de l'évolution annuelle du ratio en points (volume, fréquence, coût moyen, prime moyenne) |
| contributions_segments | Contribution de chaque segment à la hausse ou à la baisse du ratio |
| retention_cohortes | Matrice de rétention par cohorte de souscription et par produit |
| retention_multidetention | Rétention des clients multi-détenteurs et mono-détenteurs |
| valeur_client | Primes acquises moins sinistres payés, par client |
| delais_sinistres | Délais de déclaration, de premier règlement et de clôture par sinistre |
| evolution_mensuelle | Primes, sinistres et ratio chaque mois, avec comparaison à l'année précédente |
| exploitation | État de la chaîne : dernier chargement par source, lignes rejetées par règle, résultats des tests |

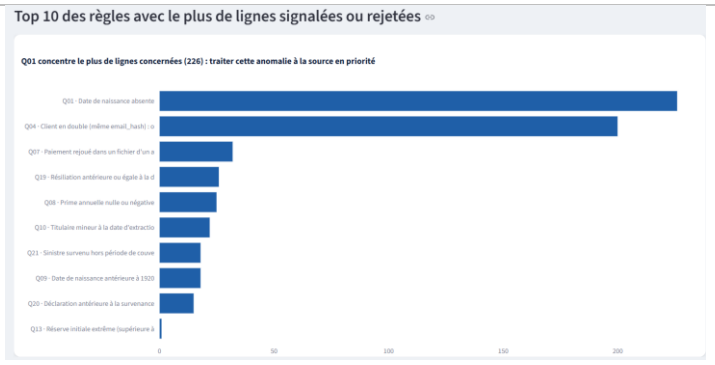
## Annexe 4 · Courbe de pareto (concentration client)




## Annexe 5 · Quelques graphiques du Dashboard




Après 4 ans, un contrat sur deux seulement subsiste : renforcer la fidélisation dès la 1re année
Cohorte
2020
2021
2022
2023
2024
92 %
80 %
69 %
59 %
52 %
93 %
80 %
69 %
59 %
94 %
80 %
70 %
93 %
81 %
94 %
0 an(s)
1 an(s)
2 an(s)
3 an(s)
4 an(s)
%
100
80
60
40
20
0


Top 10 des règles avec le plus de lignes signalées ou rejetées
Q01 concentre le plus de lignes concernées (226) : traiter cette anomalie à la source en priorité
Q01 - Date de naissance absente
Q04 - Client en double (même email_hash) : ce
Q07 - Paiement rejoué dans un fichier d'un a
Q19 - Résiliation antérieure ou égale à la d
Q08 - Prime annuelle nulle ou négative
Q10 - Titulaire mineur à la date d'extractio
Q21 - Sinistre survenu hors période de couve
Q09 - Date de naissance antérieure à 1920
Q20 - Déclaration antérieure à la survenance
Q13 - Réserve initiale extrême (supérieure à
0
50
100
150
200